AV2 Seeds
Classificação de variedades de trigo

Gabriel Felix
Execução antecipada: 06/11/2026
Entrega final prevista: 04/12/2026

Pergunta e hipótese

As sete características geométricas do dataset Seeds permitem prever a variedade de um grão de trigo?

Hipótese: um modelo treinado com essas características supera uma regra que sempre prevê uma única classe.

Resultado observado

A árvore refinada acertou 39 de 42 grãos: acurácia 92,86% e F1 macro 0,9263. A referência sempre prevê Kama no treino completo e acerta 14/42 (33,33%). O ganho foi de 59,52 pontos percentuais. O intervalo de Wilson de 95% da acurácia é 80,99% a 97,54%, sob aproximação binomial para este teste. AUC macro um-contra-resto: 0,9226. AUC mede ordenação dos escores, não a taxa de acertos.

Escopo dos dados

Dados: Charytanowicz et al. (2010), Seeds, UCI, DOI 10.24432/C5H30K, CC BY 4.0. A ficha UCI informa os nomes, mas não explicita o mapa dos códigos. A documentação mantida pelos autores do ODRF confirma 1=Kama, 2=Rosa, 3=Canadian. Ela descreve uma versão de 209 linhas, usada aqui apenas para o mapa semântico. Toda a análise usa as 210 linhas do bruto local da UCI.

As entradas são sete medidas numéricas. A saída é uma das três classes. Este trabalho usa a tabela já extraída pelos pesquisadores, sem processamento de imagens. Não há submissão externa realizada.

1. Qualidade e preparação

Auditoria executada: 210 linhas, sete medidas contínuas e uma classe nominal codificada por inteiro. Zero ausentes, zero duplicatas de linhas ou de X, zero valores não finitos e zero medidas não positivas. O arquivo foi lido com `pandas.read_csv(sep=r"\s+", header=None)`, nomes explícitos e conversão numérica validada. Nenhum registro foi removido ou valor corrigido. O bruto mantém o mesmo SHA-256 antes e depois.

Verificação	Resultado
Dimensões	210 grãos, sete atributos e classe
Faltantes / duplicatas / medidas não positivas	0 / 0 / 0
Bruto	Conteúdo preservado por SHA-256
Transformação	Nomes e tipos explícitos, nenhuma exclusão

A diferença máxima da compacidade para $4\pi A/P^2$ é 0,001020. Não houve recálculo. As unidades físicas não foram presumidas. Identificador da linha, nome da variedade e partição ficam fora das entradas do modelo.

A divisão estratificada 80/20, semente 42, precede EDA e seleção supervisionada. São 168 exemplos de treino (56 por classe) e 42 de teste (14 por classe). Validação cruzada estratificada de cinco folds, com embaralhamento e semente 42, usa apenas treino. O seletor SelectKBest com ANOVA f_classif fica no Pipeline e reaprende as colunas em cada fold. Não há normalização no classificador de árvore, imputação ou reamostragem. As classes já estão equilibradas. Os códigos 1, 2, 3 são categorias, sem ordem quantitativa.

No treino, seis grãos têm extremos pelo critério de 1,5 IQR: quatro em compacidade e dois em assimetria. Mantivemos os valores, pois não há evidência de medição incorreta.

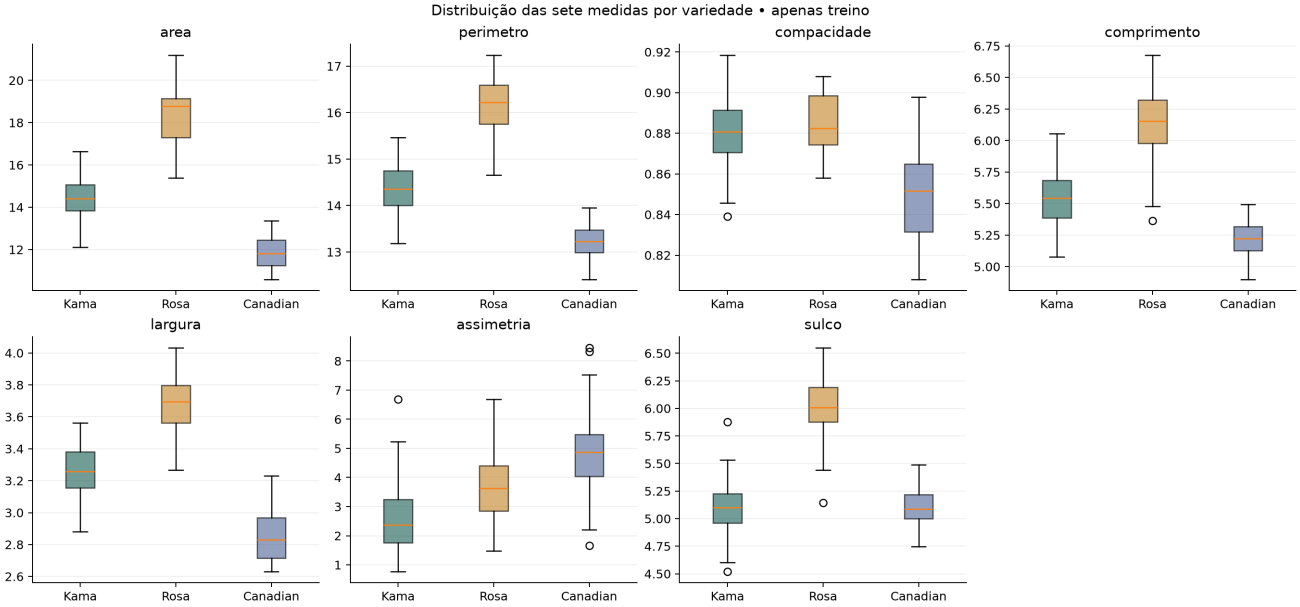


Figura 1. Distribuições por classe nos 168 grãos de treino.

2. EDA e seleção de atributos

A EDA usa somente os 168 grãos de treino. A correlação de Pearson entre área e perímetro foi 0,9945. Essa redundância ajuda a explicar por que escolher apenas os três maiores escores univariados pode descartar informação complementar. O critério de 1,5 IQR sinalizou quatro valores de compacidade e dois de assimetria, em seis grãos. Mantivemos esses registros por não existir evidência de erro de medição. No treino, a média da área foi 14,43 em Kama, 18,36 em Rosa e 11,87 em Canadian, enquanto a média da assimetria foi 2,58, 3,66 e 4,82, respectivamente. Há sobreposição entre distribuições.

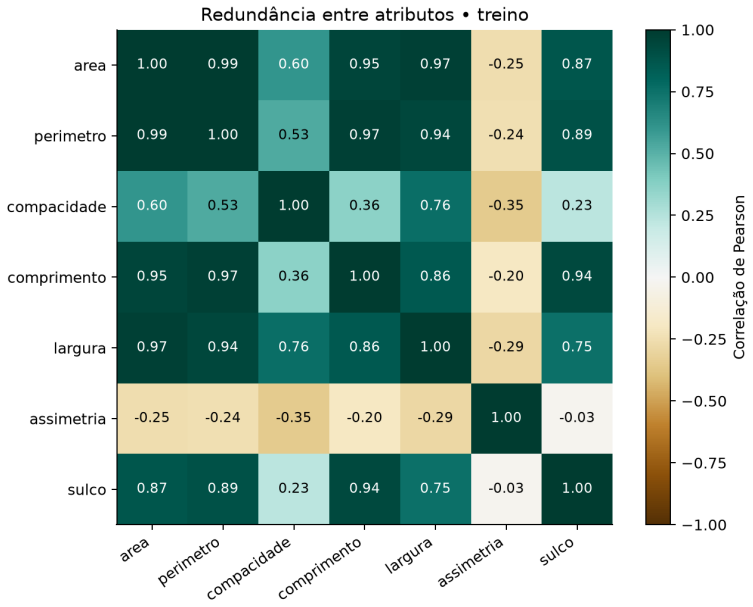


Figura 2. Correlações de Pearson no treino.

Atributo	F ANOVA	k=3
area	466,65	Sim
perimetro	464,78	Sim
largura	347,07	Sim
sulco	302,30	Não
comprimento	275,49	Não
compacidade	57,79	Não
assimetria	45,73	Não

O filtro ANOVA considera cada variável isoladamente. Os três candidatos incluem área e perímetro, fortemente correlacionados. Seletores reaprendem o ranking dentro de cada fold. Valores-p são exploratórios, sem uso confirmatório.

3. Treinamento e refinamento

A referência Dummy prevê a classe mais frequente. Árvores iniciais comparam os sete atributos a k=3. Usamos Gini, semente 42, folha mínima 1 e profundidade irrestrita nessa comparação inicial.

A busca testa 240 configurações e 1.200 ajustes de validação: k em [2,3,4,5,6,all], profundidade em [2,3,4,5,None], folha mínima em [1,2,4,6] e ccp_alpha em [0,0.01]. F1 macro médio escolhe a configuração. Empates numéricos usam acurácia, menos atributos, menor profundidade, maior folha mínima e maior poda, nessa ordem. A comparação usa os mesmos folds. O melhor resultado de CV é um critério de seleção e pode ser otimista após a busca. O desvio padrão entre folds não é um intervalo de confiança.

Modelo	Acurácia CV	F1 macro CV	DP do F1
Referência simples	32,75%	0,1644	0,0018
Árvore inicial (7)	89,86%	0,8984	0,0406
Árvore inicial (k=3)	83,33%	0,8340	0,0488
Árvore refinada	92,26%	0,9231	0,0527

A configuração escolhida aceita os sete atributos, usa Gini, max_depth=5, min_samples_leaf=1, ccp_alpha=0.01 e random_state=42. A árvore resultante tem 5 níveis de profundidade e 8 folhas. Seus cortes efetivos usam área, comprimento, largura, assimetria e sulco. Perímetro e compacidade continuam na entrada, mas não aparecem nos cortes da árvore final.

As árvores iniciais alcançaram 100% no treino interno, com desempenho inferior na validação. A refinada alcançou 98,66% no treino médio dos folds e 92,26% na validação. Há sensibilidade residual, mesmo com a poda escolhida.

A configuração final e o pipeline são salvos antes de gerar previsões no teste. A comparação dos quatro modelos no teste é descritiva e predefinida. Não há ajuste posterior orientado por essa avaliação.

4. Avaliação final

Modelo	Treino	Teste	F1 macro	Acertos
Referência simples	33,33%	33,33%	0,1667	14/42
Árvore inicial (7)	100,00%	88,10%	0,8766	37/42
Árvore inicial (k=3)	100,00%	83,33%	0,8226	35/42
Árvore refinada	98,81%	92,86%	0,9263	39/42

Classe	Precisão	Recall	F1	Suporte
Kama	100,00%	78,57%	0,8800	14
Rosa	93,33%	100,00%	0,9655	14
Canadian	87,50%	100,00%	0,9333	14

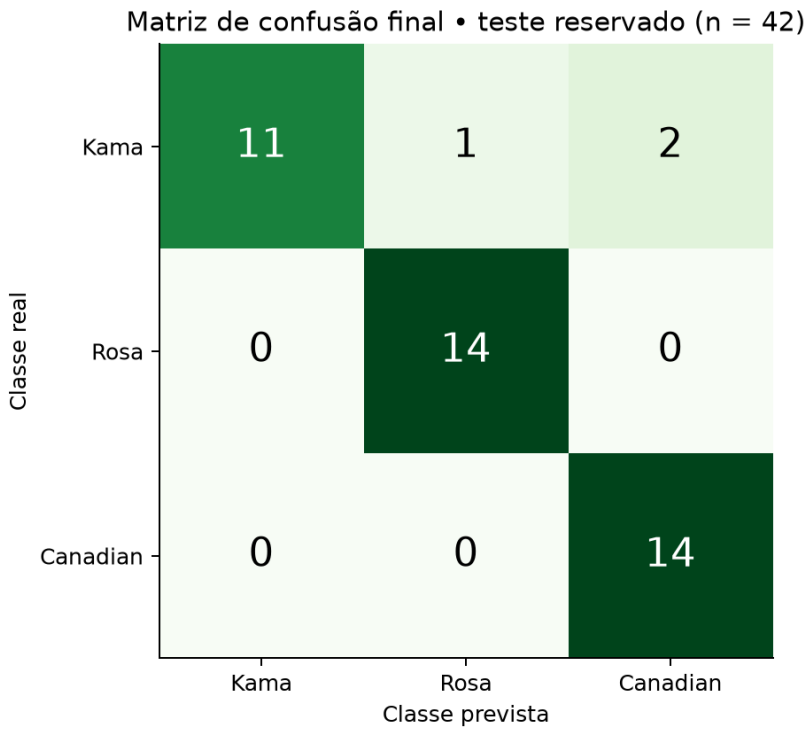


Figura 3. Linhas são classes reais, colunas são classes previstas.

A árvore refinada acertou 39 de 42 grãos: acurácia 92,86% e F1 macro 0,9263. A referência sempre prevê Kama no treino completo e acerta 14/42 (33,33%). O ganho foi de 59,52 pontos percentuais. O intervalo de Wilson de 95% da acurácia é 80,99% a 97,54%, sob aproximação binomial para este teste. AUC macro um-contra-resto: 0,9226. AUC mede ordenação dos escores, não a taxa de acertos.

Precisão: acertos entre previsões da classe. Recall: acertos entre exemplos reais da classe. F1 combina ambos. As três classes têm o mesmo peso no F1 macro.

5. Casos classificados incorretamente

Linha	Real	Previsto	Folha	Treino na folha
24	Kama	Canadian	5	48
62	Kama	Canadian	5	48
38	Kama	Rosa	13	1

Todos os erros finais são Kama: dois classificados como Canadian e um como Rosa. As linhas 24 e 62 caem na mesma região de área pequena e sulco acima de 4,675, com folha formada por 48 Canadian no treino. Os vizinhos nos sete atributos incluem ambas as classes. A linha 38 tem área 17,08 e largura 3,683 e alcança uma folha Rosa formada por apenas um grão de treino. Isso evidencia fragilidade local da árvore. As proporções de classe nas três folhas erradas são 100% para a classe prevista, mostrando que pureza de folha não equivale a certeza de acerto. Não há evidência para atribuir os erros a defeitos, rótulos incorretos ou causas biológicas. O diagnóstico é descritivo e não gerou novo ajuste após consultar o teste.

Linha 24: Kama como Canadian

Caminho: sulco=4.961 <= 5.5755; area=12.08 <= 13.435; area=12.08 <= 12.71; sulco=4.961 > 4.675.

Vizinho mais próximo no treino: linha 65, classe 1, distância padronizada 0,726. A padronização usa somente estatísticas do treino para diagnóstico.

Linha 62: Kama como Canadian

Caminho: sulco=4.703 <= 5.5755; area=11.23 <= 13.435; area=11.23 <= 12.71; sulco=4.703 > 4.675.

Vizinho mais próximo no treino: linha 166, classe 3, distância padronizada 1,024. A padronização usa somente estatísticas do treino para diagnóstico.

Linha 38: Kama como Rosa

Caminho: sulco=5.484 <= 5.5755; area=17.08 > 13.435; largura=3.683 > 3.572.

Vizinho mais próximo no treino: linha 36, classe 1, distância padronizada 0,934. A padronização usa somente estatísticas do treino para diagnóstico.

Todos os valores, caminhos e três vizinhos de cada erro estão nos arquivos erros_teste.csv e erros_detalhados.json. Não modificamos o modelo após esta leitura.

6. Interpretação e conclusão

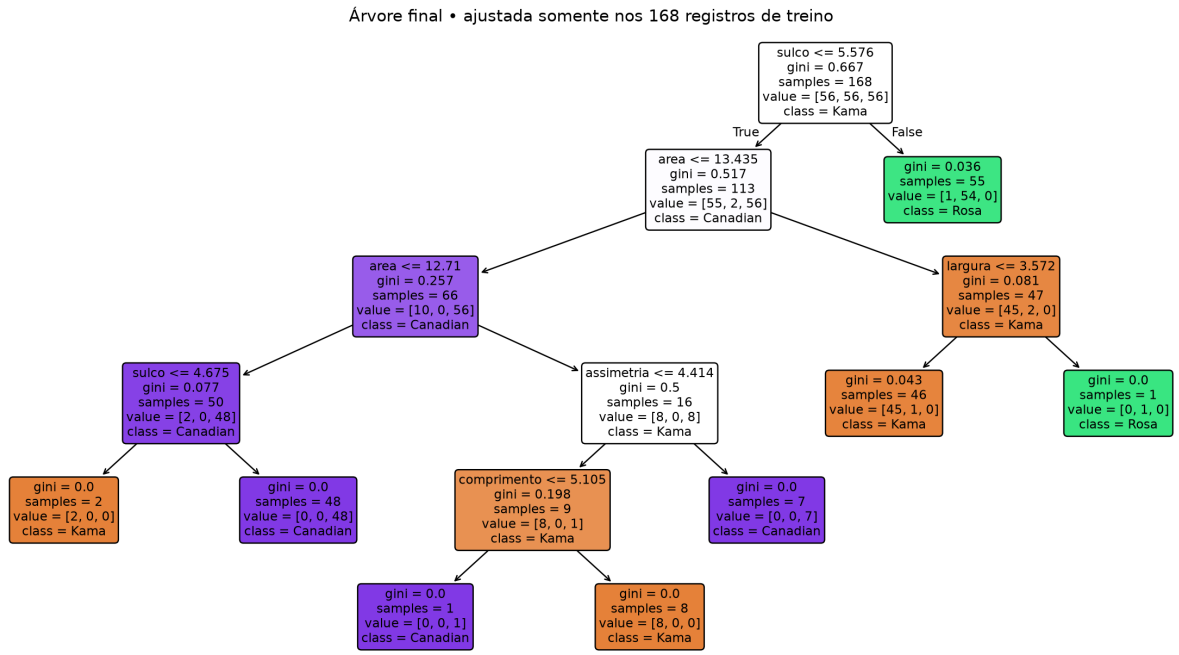


Figura 4. Árvore final treinada nos 168 exemplos. Regras em texto também disponíveis.

A hipótese foi sustentada nesta avaliação: a árvore refinada supera a regra de classe única. O subconjunto inicial de três atributos teve desempenho inferior. A entrada final mantém sete medidas, e cinco aparecem nos cortes.

O teste contém apenas 42 exemplos e uma única divisão. Um erro representa 2,38 pontos percentuais de acurácia e 7,14 pontos no recall de uma classe. Não há avaliação em nova safra, local, instrumento ou protocolo de medição. A UCI descreve coleta em campos experimentais em Lublin. A hipótese fica sustentada nesta divisão, sem demonstrar desempenho universal, causalidade ou superioridade sobre todos os classificadores. A busca escolheu uma folha mínima de 1, mantendo risco local mesmo com poda. O teste já consultado não serve como avaliação inédita de versões futuras. Não fizemos teste formal de significância nem apresentamos um valor-p como prova da hipótese.

7. Ciclo de vida e entregas

Marco	Trabalho preparado
13/11	Limpeza, pré-processamento, EDA e candidatos
20/11	Divisão e treinamento. Envio previsto no feriado
27/11	Refinamento no treino, avaliação final e erros
04/12	Relatório, apresentação e inferência local

O slide foi consultado da página física 10 à 130. As p. 52 e 130 incluem implantação e monitoramento, ausentes no encerramento do plano inicial. As p. 68-70 e 81 reservam teste ao fim. A p. 74 pede referência simples, e as p. 77-79 descrevem múltiplas métricas.

Implantação local executada

Exportamos o pipeline Joblib e um programa de previsão em lote. Ele valida entradas e sinaliza valores fora dos intervalos do treino. O exemplo usa três grãos já conhecidos e verifica a interface. As proporções nas folhas não são probabilidades calibradas.

Monitoramento proposto

Validar cada novo lote, revisar distribuições mensalmente e avaliar métricas quando existirem rótulos independentes. Investigar mudanças de instrumento, origem e unidade. O plano detalhado propõe gatilhos a validar e nova reserva de teste para versões futuras. Não há sistema de produção ou medições de drift observadas.

Arquivos e próximos passos

O README e o manifesto organizam entregas, fontes, dados derivados, gráficos, tabelas, código e modelo. As quatro entregas estão preparadas antecipadamente. Gabriel deve revisar os materiais e realizar os envios nas datas previstas.

8. Reprodução e referências

Python 3.12.14. Versões: pandas 3.1.1, numpy 2.5.4, scipy 1.18.1, scikit-learn 1.9.1, matplotlib 3.11.2, joblib 1.6.0.

Na raiz do projeto, criar um ambiente Python 3.12, instalar requirements.txt e executar os comandos abaixo. O README contém os comandos PowerShell completos e a geração da apresentação.

```
python -m pip install -r requirements.txt

python src/analise_seeds.py

python src/gerar_relatorios.py

python src/prever.py dados/exemplo_inferencia.csv --saida resultados/previsoes_exemplo.csv

python src/verificar_resultados.py
```

O código resolve caminhos a partir da própria pasta do projeto. Reexecutar reproduz o mesmo experimento, sem transformar o teste conhecido em uma nova avaliação independente.

Referências e rastreabilidade

Charytanowicz, M., Niewczas, J., Kulczycki, P., Kowalski, P., & Lukasik, S. (2010). Seeds [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C5H30K. Licença CC BY 4.0.

https://archive.ics.uci.edu/dataset/236/seeds

https://doi.org/10.24432/C5H30K

https://raw.githubusercontent.com/liuyu-star/ODRF/master/man/seeds.Rd

https://scikit-learn.org/stable/common_pitfalls.html

Material da disciplina: slide-machine-learning.pdf, páginas físicas 10-130. Mapa detalhado em relatorios/aderencia_slide.md. Cópia da documentação de classes em fontes/ODRF_seeds.Rd.

SHA-256 do bruto

1f3f83c0d8485ae9148061389d196286
07e3f5660e3d6f40ec9102fb398bb12f

Nenhum conteúdo do bruto ou da entrega inicial foi alterado. Os resultados numéricos provêm da execução local, registrados em resultados/resumo_execucao.json.